| Regresi dan Data Outlier | | |
|---|---|---|
| Praktikan | **Aslab** | |
| Nama: xxxx<br>Nim: xxxx | Annur Hangga Prihadi | 065001800028 |
| | Faiz Kumara | 065001800003 |

**PRAKTIKUM 6**

**DATA SAINS DAN ANALITIK**

Topik pertemuan praktikum ke-enam adalah mengolah data harga emas menggunakan metode regresi linier sederhana dan mengetahui seberapa banyak outlier yang berada di data harga emas.

**Source Code:**

https://github.com/hanggaa/PrakDSDA/blob/main/Prak_6_MSE.ipynb

## Latihan 1

### 1. Memasang library yang dibutuhkan

```
In [1]: import requests
        import pandas as pd
        import numpy as np
        from matplotlib import pyplot as plt
        from sklearn.linear_model import LinearRegression #Library untuk Regresi Linier
        from sklearn.metrics import mean_squared_error #Library MSE
        from sklearn.ensemble import IsolationForest #Library untuk mencari data Outlier
```

### 2. Membaca file

```
In [2]: data = pd.read_csv("C:/Users/hangg/Downloads/Random Aslab/DSDA/Material/Gold Futures Historical Data.csv", sep=";") #Sesuaikan de
```

### 3. Menampilkan n data

```
In [3]: data.head(4)
```

Out[3]:

| | Date | Price | Open | High | Low | Volume | Volatility | Fluktuasi |
|---|---|---|---|---|---|---|---|---|
| 0 | 2021 | 1,818.55 | 1,781.25 | 1,820.45 | 1,758.90 | 222.61K | 1,9 | Naik |
| 1 | 2021 | 1,783.90 | 1,757.20 | 1,815.50 | 1,745.40 | 3.92M | 1,5 | Naik |
| 2 | 2021 | 1,757.00 | 1,816.70 | 1,836.90 | 1,721.10 | 3.65M | -3,4 | Turun |
| 3 | 2021 | 1,818.10 | 1,817.00 | 1,835.90 | 1,677.90 | 3.66M | 0,3 | Netral |

4. **Menampilkan deskripsi data sebelum Pre-Processing**

```
In [4]: data.describe()
```

Out[4]:

| | Date |
|---|---|
| count | 179.000000 |
| mean | 2013.960894 |
| std | 4.312724 |
| min | 2007.000000 |
| 25% | 2010.000000 |
| 50% | 2014.000000 |
| 75% | 2018.000000 |
| max | 2021.000000 |

5. **Melihat tipe data kolom sebelum dilakukan Pre-Processing**

```
In [5]: data.dtypes

Out[5]: Date           int64
        Price         object
        Open          object
        High          object
        Low           object
        Volume        object
        Volatility    object
        Fluktuasi     object
        dtype: object
```

6. **Mengubah tipe data kolom yang diperlukan**

```
In [6]: data['Price'] = data['Price'].str.replace(',', '').astype(float)
        data['Open'] = data['Open'].str.replace(',', '').astype(float)
        data['High'] = data['High'].str.replace(',', '').astype(float)
        data['Low'] = data['Low'].str.replace(',', '').astype(float)
        data['Volatility'] = data['Volatility'].str.replace(',', '.').astype(float)
```

7. **Melihat tipe data kolom setelah dilakukan Pre-Processing**

```
In [7]: data.dtypes

Out[7]: Date           int64
        Price        float64
        Open         float64
        High         float64
        Low          float64
        Volume        object
        Volatility   float64
        Fluktuasi     object
        dtype: object
```

**8. Menampilkan deskripsi data setelah dilakukan Pre-Processing**

```
In [8]: data.describe()
```

Out[8]:

| | Date | Price | Open | High | Low | Volatility |
|---|---|---|---|---|---|---|
| count | 179.000000 | 179.000000 | 179.000000 | 179.000000 | 179.000000 | 179.000000 |
| mean | 2013.960894 | 1331.139385 | 1327.106983 | 1366.603631 | 1290.482123 | 0.715642 |
| std | 4.312724 | 315.711490 | 318.376190 | 325.603855 | 308.757162 | 5.076547 |
| min | 2007.000000 | 648.100000 | 640.400000 | 655.500000 | 607.000000 | -18.000000 |
| 25% | 2010.000000 | 1181.400000 | 1181.400000 | 1209.650000 | 1160.300000 | -2.550000 |
| 50% | 2014.000000 | 1334.300000 | 1333.100000 | 1350.200000 | 1309.000000 | 0.400000 |
| 75% | 2018.000000 | 1562.850000 | 1554.400000 | 1579.500000 | 1511.100000 | 3.700000 |
| max | 2021.000000 | 2017.100000 | 2026.900000 | 2120.000000 | 1913.000000 | 13.900000 |

**9. Mengelompokkan data rata-rata harga berdasarkan tahun**

```
In [9]: avg_gold_price = data.groupby('Date')['Price'].mean() #Mencari rata-rata harga untuk dikelompokkan berdasarkan tahun

In [10]: print('Rata-rata harga emas per tahun\n',avg_gold_price)
```

```
Rata-rata harga emas per tahun
 Date
2007     705.483333
2008     876.775000
2009     984.783333
2010    1237.783333
2011    1574.075000
2012    1676.325000
2013    1394.400000
2014    1263.933333
2015    1234.533333
2016    1305.200000
2017    1345.766667
2018    1352.216667
2019    1453.883333
2020    1805.750000
2021    1794.822727
Name: Price, dtype: float64
```

**10. Memisahkan data menjadi varibel X dan Y untuk visualisasi data**

```
In [11]: x=avg_gold_price.index
         y=avg_gold_price.values

In [12]: plt.scatter(x, y)
         plt.plot(x, y)
         plt.xlabel('Tahun')
         plt.ylabel('Rata-Rata Harga Emas')
```

```
Out[12]: Text(0, 0.5, 'Rata-Rata Harga Emas')
```

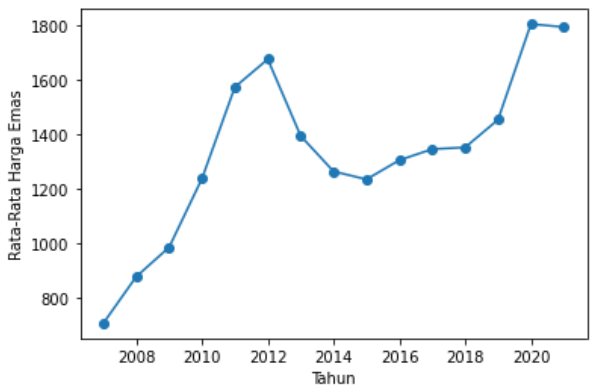

## 11. Mencari rata-rata harga Emas tahun 2022 menggunakan Regresi Linier

```
In [13]: linreg=LinearRegression()
         x=np.array(x).reshape(-1,1) #Data tahun dimasukkan kedalam ordo matrix n*1
         linreg.fit(x, y)

Out[13]: LinearRegression()

In [14]: Gold_2022=np.array(2022).reshape(-1,1) #Membuat data tahun baru yaitu tahun 2022
         pred_ipm=linreg.predict(Gold_2022)

In [15]: print('\nPrediksi rata-rata Harga Emas tahun 2022 =\n', pred_ipm.item())

         Prediksi rata-rata Harga Emas tahun 2022 =
          1745.584473304465
```

## 12. Membuat visualisasi hasil dari Regresi Linier

```
In [16]: plt.scatter(x, y)
         plt.plot(x, y)
         plt.xlabel('Tahun')
         plt.ylabel('Rata-Rata Harga Emas')
         plt.scatter(Gold_2022, pred_ipm, c='red')
         pred_y=linreg.predict(x)
         plt.plot(x, pred_y)
         plt.show()
```

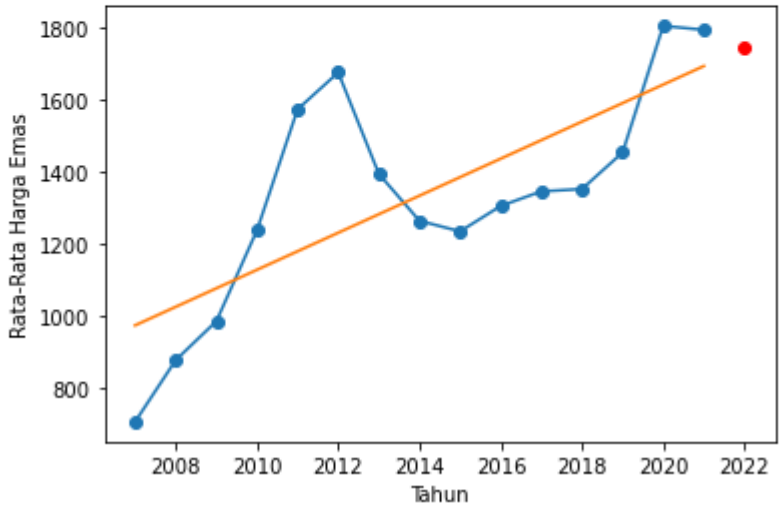


## 13. Rangkuman dari hasil Regresi Linier menggunakan indikator MSE

```
In [17]: MSE=mean_squared_error(y,pred_y)
         print('MSE = ', MSE)

         MSE =  42465.96491878305
```

## 14. Mengambil 2 kolom dari dataset

```
In [18]: dataIso = data[['Date','Volatility']] #Mengambil 2 kolom dari data yang diolah untuk mencari outlier dari volatility
```

## 15. Menentukan tingkat toleransi data outlier

```
In [19]: clf = IsolationForest(contamination=0.2) #Contamination adalah seberapa besar tingkat toleransi data yang menyimpang
         pred = clf.fit_predict(dataIso)
```

## 16. Memasukkan data outlier kedalam data frame

```
In [20]: dataIso['Outlier']=pred.reshape(-1,1) #Data outlier dimasukkan kedalam ordo matrix n*1

<ipython-input-20-01a88242edc0>:1: SettingWithCopyWarning:
A value is trying to be set on a copy of a slice from a DataFrame.
Try using .loc[row_indexer,col_indexer] = value instead

See the caveats in the documentation: https://pandas.pydata.org/pandas-docs/stable/user_guide/indexing.html#returning-a-view-versus-a-copy
  dataIso['Outlier']=pred.reshape(-1,1)
```

## 17. Mencetak hasil data outlier

```
In [21]: print(dataIso)
```

| | Date | Volatility | Outlier |
|---|---|---|---|
| 0 | 2021 | 1.9 | 1 |
| 1 | 2021 | 1.5 | 1 |
| 2 | 2021 | -3.4 | -1 |
| 3 | 2021 | 0.3 | -1 |
| 4 | 2021 | 2.3 | -1 |
| .. | ... | ... | ... |
| 174 | 2007 | -2.9 | -1 |
| 175 | 2007 | 2.6 | 1 |
| 176 | 2007 | -1.0 | 1 |
| 177 | 2007 | 2.7 | 1 |
| 178 | 2007 | 2.6 | 1 |

[179 rows x 3 columns]

**Data yang termasuk outlier memiliki value -1**

## 18. Melihat data yang termasuk outlier

```
In [22]: dataOutlier = dataIso['Volatility'].loc[dataIso['Outlier']==-1]
         print('Data yang termasuk outlier:\n', dataOutlier.value_counts())

Data yang termasuk outlier:
  13.6    2
 2.3     1
 11.0    1
 10.5    1
 0.3     1
-7.0     1
 6.6     1
```

## 19. Melihat data yang tidak termasuk outlier

```
In [23]: dataNoOutlier = dataIso['Volatility'].loc[dataIso['Outlier']==1]
         print('Data yang tidak termasuk outlier:\n', dataNoOutlier.value_counts())

Data yang tidak termasuk outlier:
  2.6    5
 0.4    5
 3.7    4
-0.7    3
-0.3    3
       ..
-5.5    1
 2.0    1
 3.6    1
-3.4    1
 4.8    1
Name: Volatility, Length: 90, dtype: int64
```

## 20. Memvisualisasikan data outlier

```
In [24]: plt.figure(figsize=(24,24))
         plt.scatter(dataIso['Date'],dataIso['Volatility'])
         plt.title('Outlier Volatility Emas', fontsize=24)

Out[24]: Text(0.5, 1.0, 'Outlier Volatility Emas')
```

**Latihan 2**

1. Cari hasil prediksi harga (Open) Emas pada tahun 2022 menggunakan metode regresi linier sederhana

**Lampiran Screenshot hasil**

| |
|---|
| **Input screenshot disini** |

**Jelaskan perbandingan makna hasil dari MSE harga (Price) dengan harga (Open)**

| |
|---|
| **Ketik makna disini** |